

Informe Final

Priorización de Casos Clínicos Bajo Recursos Limitados

Proyecto Final de Inteligencia Artificial y Simulación

2026

Repositorio	https://github.com/hughescard/AI-Clinical_Priority_Simulation
Fuente de datos	mimic_iv_ed
Proveedor LLM final	Ollama local
Modelo LLM	llama3.2:3b

Resumen

Este proyecto desarrolla un sistema de simulación y planificación inteligente para priorizar pacientes en un servicio de urgencias bajo restricciones de recursos clínicos. El sistema integra una simulación de eventos discretos, un módulo de enriquecimiento clínico mediante LLM, un conjunto de algoritmos de planificación y una capa de evaluación experimental reproducible.

La corrida experimental final evaluó cinco algoritmos: FIFO, Greedy, A^* , CP-SAT y Simulated Annealing. Se ejecutaron tres escenarios: condiciones normales, alta demanda y recursos limitados. Cada combinación de escenario y algoritmo fue evaluada con 10 réplicas de 480 minutos, para un total de 150 simulaciones. El enriquecimiento clínico de la corrida final utilizó Ollama local con el modelo llama3.2:3b, con cero fallbacks a mock y 3200 ejecuciones exitosas registradas del proveedor Ollama.

Los resultados muestran que A^* obtuvo el mejor ranking global balanceado en los tres escenarios. FIFO conservó la ventaja computacional por su bajo overhead de planificación, mientras que Simulated Annealing fue competitivo en métricas clínicas y operativas. CP-SAT no dominó en este entorno dinámico, lo que sugiere que su utilidad puede ser mayor en horizontes de optimización más estáticos o globales.

1. Descripción del problema

Los servicios de urgencias operan bajo incertidumbre y presión de recursos. La llegada de pacientes no es completamente predecible, los niveles de riesgo pueden cambiar durante la espera, y los recursos clínicos —médicos, enfermeros, camas, monitores y salas especializadas— son limitados. En ese contexto, la decisión de qué paciente atender primero no puede depender únicamente del orden de llegada.

El problema abordado consiste en seleccionar, en cada instante de decisión, qué paciente o grupo de pacientes debe recibir atención, considerando:

- el riesgo clínico inicial;
- el deterioro esperado durante la espera;
- el tiempo máximo recomendable antes de atención;
- los recursos requeridos por cada paciente;
- la disponibilidad de recursos;
- el impacto operativo de cada algoritmo de decisión.

El objetivo no es reemplazar una decisión médica real, sino construir un entorno experimental para comparar estrategias algorítmicas de priorización bajo condiciones controladas.

2. Modelado formal

El sistema se modela como una simulación de eventos discretos con planificación periódica y despacho continuo.

Sea:

- $P = \{p_1, p_2, \dots, p_n\}$ el conjunto de pacientes.
- $R = \{r_1, r_2, \dots, r_m\}$ el conjunto de recursos clínicos.
- c_r la capacidad disponible del recurso $r \in R$.
- $Q_i \subseteq R$ el conjunto de recursos requeridos por el paciente p_i .
- a_i el tiempo de llegada del paciente.
- s_i el tiempo estimado de servicio.
- w_i^{max} el tiempo máximo recomendado de espera.
- λ_i la tasa de deterioro estimada.
- $\rho_i(t)$ el riesgo clínico dinámico del paciente en el tiempo t .

Una formulación simplificada del deterioro puede expresarse como:

$$\rho_i(t) = \rho_i(a_i) + \lambda_i \cdot (t - a_i)$$

para pacientes que permanecen en espera. La simulación mantiene una cola de eventos:

$$E = \{(t, \text{tipo}, \text{paciente}, \text{metadatos})\}$$

ordenada por tiempo. Cada evento actualiza el estado del sistema y puede generar nuevos eventos.

La asignación de un paciente es factible si sus recursos requeridos están disponibles:

$$\forall r \in R: \sum_{p_i \in S_t} \mathbf{1}(r \in Q_i) \leq c_r(t)$$

donde S_t es el conjunto de pacientes seleccionados para iniciar servicio en el tiempo t .

La evaluación experimental se realiza sobre un vector de métricas, no sobre un único objetivo clínico. Conceptualmente, el sistema busca reducir:

$$J = \alpha \cdot \overline{W} + \beta \cdot L_{crit} + \gamma \cdot I_{clin} + \eta \cdot H$$

donde $\overline{W}$ es la espera promedio, L_{crit} es el número de pacientes críticos atendidos tarde, I_{clin} es el impacto clínico acumulado y H es el overhead de planificación.

3. Dataset utilizado

La validación final usa la fuente `mimic_iv_ed`, basada en MIMIC-IV-ED Demo. MIMIC-IV-ED es una base de datos de admisiones al departamento de emergencias del Beth Israel Deaconess Medical Center entre 2011 y 2019, con datos desidentificados y variables relevantes para análisis de urgencias, como triaje y signos vitales [1]. MIMIC-IV forma parte de la familia de bases de datos clínicas públicas mantenidas a través de PhysioNet [2, 3].

En la implementación, el dataset se consume mediante una capa de ingesta que normaliza los registros hacia el modelo interno de paciente. El archivo configurado para la corrida final fue:

```
../data/raw/mimic-iv-ed-demo/ed/triage.csv
```

El dataset no se versiona en Git por razones de tamaño, permisos y reproducibilidad controlada. En el repositorio se conserva la configuración y los artefactos agregados de resultados.

3.1. Adecuación al problema

El dataset cumple con las condiciones del problema porque contiene información clínica inicial de pacientes de urgencias, lo que permite construir casos con nivel de urgencia, signos vitales, información de triaje, variables de riesgo, estimaciones de recursos necesarios y escenarios comparables entre algoritmos.

4. Arquitectura general

El sistema se organiza en cinco componentes principales.

4.1. Backend FastAPI

El backend expone endpoints para ejecutar simulaciones individuales, comparar algoritmos por escenario, exportar resultados, analizar rankings y validar configuraciones.

4.2. Motor de simulación

El motor implementa una simulación de eventos discretos. Los eventos principales son llegada de paciente, evaluación inicial, inicio de servicio, fin de servicio, actualización de deterioro, inicio y fin de ronda médica e intento de despacho.

4.3. Enriquecimiento clínico con LLM

El módulo LLM convierte información clínica textual en variables estructuradas usadas por el simulador y los algoritmos.

4.4. Módulo de planificación

Incluye algoritmos FIFO, Greedy, A^* , CP-SAT y Simulated Annealing.

4.5. Frontend

El frontend React permite ejecutar simulaciones, comparar algoritmos, visualizar rankings, revisar líneas temporales y configurar recursos avanzados.

5. Modelo de simulación

La simulación representa una jornada operativa de urgencias durante 480 minutos. Los pacientes llegan, son evaluados, esperan si no hay recursos disponibles y pueden deteriorarse durante la espera.

5.1. Flujo de eventos

1. Llegada del paciente.
2. Evaluación inicial.
3. Intento de despacho.
4. Inicio de servicio.
5. Fin de servicio.
6. Actualización de deterioro.
7. Ronda médica.

5.2. Rondas médicas no instantáneas

A diferencia de un checkpoint instantáneo, las rondas médicas se modelan como eventos con duración simulada. En `DOCTOR_ROUND_START` se calcula la duración de la ronda a partir de la duración base, el número de pacientes esperando y el overhead de planificación del algoritmo. La planificación se aplica en `DOCTOR_ROUND_END`, no al inicio de la ronda. Durante la ronda, el tiempo sigue avanzando y otros eventos pueden ocurrir normalmente.

5.3. Recursos

Los recursos base del sistema son `doctor`, `nurse`, `observation_bed`, `resuscitation_room`, `vital_sign_monitor` y `laboratory`. La corrida final habilitó además `xray_room`, `ct_scanner`, `ultrasound_room`, `isolation_room`, `pharmacy` y `specialist`.

6. Rol del LLM en el sistema

El LLM no decide directamente qué paciente atender. Su rol es enriquecer cada caso clínico con variables estructuradas para que el simulador y los algoritmos puedan operar sobre ellas. La salida esperada incluye síntomas clave, categoría clínica, puntuación textual de riesgo, tasa de deterioro, tiempo máximo de espera, tiempo estimado de servicio, recursos requeridos y explicación breve.

Campo	Valor
Fuente de datos	mimic_iv_ed
Proveedor LLM final	ollama
Modelo	llama3.2:3b
Escenarios	normal, high_demand, limited_resources
Algoritmos	fifo, greedy, astar, cpsat, simulated_annealing
Réplicas	10
Duración por simulación	480 minutos
Recursos avanzados	True
Fallback observado	0
Corrida válida para informe	True

Tabla 1: Configuración de la corrida experimental final.

6.1. Validación del uso del LLM

El resumen de uso registrado fue:

- corridas totales: 150;
- proveedor usado: Ollama;
- éxitos de Ollama: 3200;
- fallos de Ollama: 0;
- éxitos de mock: 0;
- fallbacks totales: 0;
- cache hits: 3035;
- cache misses: 165.

* Mistral permanece como proveedor alternativo soportado por el software, pero no fue usado en la corrida final reportada.

6.2. Recursos requeridos por el LLM

Recurso	Conteo requerido por LLM
doctor	165
nurse	163
vital_sign_monitor	149
resuscitation_room	63
observation_bed	47
laboratory	16
xray_room	7
isolation_room	3
pharmacy	1

Tabla 2: Recursos requeridos por el LLM según el conteo de la cache final.

Estos conteos representan recursos solicitados por el enriquecimiento clínico, no necesariamente asignaciones finales, porque el artefacto experimental agregado no preserva trazas completas de asignación de recursos por paciente.

7. Diseño de los algoritmos

El módulo de planificación compara cinco estrategias de priorización con distintos niveles de complejidad. La idea no es asumir que existe un único algoritmo óptimo para todos los escenarios, sino estudiar cómo cambia el desempeño cuando la decisión considera solamente el orden de llegada, reglas heurísticas clínicas, búsqueda informada, optimización con restricciones o exploración metaheurística.

Todos los algoritmos reciben como entrada el estado actual de la simulación: pacientes en espera, riesgo clínico, tiempo acumulado de espera, deterioro estimado, recursos requeridos y capacidad disponible. La salida esperada es una decisión de despacho: qué paciente o conjunto de pacientes debe iniciar servicio cuando los recursos lo permiten.

7.1. FIFO

FIFO (*First In, First Out*) atiende a los pacientes según el orden de llegada. En el sistema funciona como línea base porque representa una política operativa simple, transparente y de bajo costo computacional.

Su principal ventaja es que no requiere cálculo clínico complejo ni exploración de alternativas: basta con mantener una cola ordenada por tiempo de llegada. Por esta razón, FIFO obtiene el mejor comportamiento computacional en los experimentos y produce un overhead de planificación mínimo.

Sin embargo, su principal limitación es que trata a todos los pacientes en espera como si fueran equivalentes desde el punto de vista clínico. Un paciente con mayor riesgo o mayor tasa de deterioro puede quedar detrás de otro menos urgente solo porque llegó después. Por tanto, FIFO es útil como referencia de comparación, pero no como estrategia suficiente cuando el objetivo incluye reducir espera crítica o impacto clínico acumulado.

7.2. Greedy

El algoritmo Greedy introduce información clínica y operativa en la decisión. En lugar de atender únicamente por orden de llegada, calcula una prioridad local para cada paciente usando variables como riesgo, deterioro, tiempo de espera y factibilidad de recursos.

Su ventaja es que mejora la expresividad clínica respecto a FIFO sin aumentar demasiado el costo computacional. En cada instante decide con base en la mejor opción aparente según la función de prioridad definida. Esto lo hace rápido, interpretable y fácil de integrar en una simulación dinámica.

La limitación de Greedy es que toma decisiones locales sin analizar suficientemente sus consecuencias futuras. Puede elegir un paciente que parece prioritario en el momento actual, pero que consume recursos críticos y retrasa a otros pacientes que podrían deteriorarse más rápido. Por eso, aunque Greedy utiliza más información que FIFO, no necesariamente supera a FIFO en todos los escenarios. Sus resultados muestran que incorporar heurísticas clínicas no garantiza una mejora global si no se evalúa el efecto combinado de espera, recursos y deterioro.

7.3. A*

A* se diseñó como una estrategia de búsqueda informada sobre una ventana acotada de pacientes candidatos. A diferencia de Greedy, no se limita a escoger la mejor opción inmediata, sino que evalúa alternativas usando una combinación de costo acumulado y estimación heurística.

En este proyecto, el costo refleja factores como espera, criticidad, deterioro e impacto clínico. La heurística orienta la búsqueda hacia decisiones que reduzcan la atención tardía de pacientes críticos y el tiempo de espera acumulado. Así, A* actúa como un planificador local más deliberativo: explora varias posibilidades antes de seleccionar el despacho.

Su fortaleza es que logra un mejor equilibrio clínico-operativo. Esto se observa en los resultados finales, donde A* obtiene el primer lugar balanceado en los tres escenarios y reduce de forma importante la espera promedio frente a FIFO. La desventaja es su mayor overhead de planificación. A* requiere más cómputo que FIFO y Greedy porque evalúa múltiples estados candidatos, aunque ese costo fue modelado como overhead simulado y no como tiempo real de ejecución.

En el contexto del proyecto, A* representa una estrategia adecuada cuando se prioriza la calidad de la decisión clínica por encima de la simplicidad computacional.

7.4. CP-SAT

CP-SAT formula la decisión de despacho como un problema de optimización con restricciones. Cada paciente candidato puede representarse mediante una variable binaria que indica si será seleccionado o no, y las restricciones controlan que la suma de recursos requeridos no supere la capacidad disponible.

La ventaja de CP-SAT es su claridad formal. Permite expresar explícitamente restricciones de recursos, factibilidad de asignación y una función objetivo asociada a utilidad clínica u operativa. Esto lo hace atractivo para problemas donde se necesita justificar matemáticamente por qué una asignación es factible.

No obstante, en este proyecto CP-SAT se aplica dentro de una simulación dinámica de eventos discretos y sobre ventanas locales de decisión. Esto limita su capacidad para explotar todo su potencial, porque no optimiza un horizonte hospitalario completo, sino

decisiones parciales en momentos específicos. Además, la construcción y resolución del modelo introduce overhead adicional.

Los resultados muestran que CP-SAT no domina el ranking global. Esto no implica que el enfoque sea inadecuado, sino que su ventaja natural aparece mejor en contextos de planificación más estáticos, con horizontes más amplios o con agendas globales de recursos. En una sala de urgencias simulada con llegadas, deterioro y liberación continua de recursos, la optimización exacta local puede resultar menos competitiva que una búsqueda informada como A*.

7.5. Simulated Annealing

Simulated Annealing se incorporó como una metaheurística para explorar soluciones alternativas cuando una decisión puramente local puede quedar atrapada en un mal ordenamiento. Parte de una solución inicial, normalmente cercana a una política heurística, y genera modificaciones sobre el orden de atención. A diferencia de Greedy, puede aceptar temporalmente soluciones peores con cierta probabilidad, lo que le permite escapar de óptimos locales.

En el sistema, esta estrategia es útil porque el problema combina riesgo clínico, espera, deterioro y restricciones de recursos. La mejor asignación inmediata no siempre conduce al mejor resultado acumulado. Simulated Annealing intenta mejorar esa situación explorando configuraciones cercanas antes de decidir.

Su principal ventaja es la capacidad de búsqueda flexible sin requerir una formulación exacta como CP-SAT. En los resultados, fue competitivo en métricas clínicas y operativas, especialmente en impacto clínico total y en el escenario de recursos limitados, donde alcanzó el segundo lugar balanceado.

Su principal costo es el overhead. Al evaluar múltiples vecinos y mantener una dinámica de aceptación probabilística, requiere más tiempo de planificación que FIFO, Greedy y A*. Por tanto, su uso es más justificable cuando se busca mejorar el desempeño clínico bajo restricciones fuertes y se acepta un mayor costo computacional.

7.6. Comparación conceptual de los enfoques

Los cinco algoritmos representan distintos niveles de sofisticación:

- FIFO prioriza simplicidad y trazabilidad.
- Greedy introduce criterio clínico local con bajo costo adicional.
- A* realiza búsqueda informada para mejorar el equilibrio entre espera, criticidad y deterioro.
- CP-SAT ofrece una formulación formal con restricciones explícitas de recursos.
- Simulated Annealing explora alternativas para escapar de decisiones localmente atractivas pero globalmente débiles.

Esta diversidad permite evaluar no solo cuál algoritmo obtiene mejores métricas, sino también qué tipo de compromiso existe entre desempeño clínico, eficiencia operativa y overhead computacional.

8. Metodología experimental

La corrida final se diseñó para comparar los algoritmos bajo las mismas condiciones de datos, semillas y duración.

- Escenarios: `normal`, `high_demand`, `limited_resources`.
- Algoritmos: `fifo`, `greedy`, `astar`, `cpsat`, `simulated_annealing`.
- Réplicas: 10 por combinación escenario-algoritmo.
- Duración de cada simulación: 480 minutos.
- Total de simulaciones: 150.
- Fuente de datos: MIMIC-IV-ED Demo.
- Proveedor LLM final: Ollama local.
- Modelo LLM: `llama3.2:3b`.
- Recursos avanzados: habilitados.
- Fallback permitido para informe: ninguno.

Las métricas principales fueron pacientes atendidos, pacientes no atendidos, espera promedio, espera máxima, pacientes críticos atendidos tarde, impacto clínico total, utilización promedio de recursos, tiempo total de rondas médicas, duración promedio de ronda médica y overhead de planificación.

9. Resultados y análisis

9.1. Ranking global

Rango	Algoritmo	Score balanceado promedio	Rango promedio	Mejor rango	Primeros lugares
1	A*	0.94	1.0	1	3
2	FIFO	0.856667	2.3333	2	0
3	Simulated Annealing	0.856666	2.6667	2	0
4	CP-SAT	0.784444	4.0	4	0
5	Greedy	0.757778	5.0	5	0

Tabla 3: Ranking global balanceado por algoritmo.

A* obtuvo el primer lugar promedio en los tres escenarios. FIFO ocupó el segundo lugar global por su fortaleza computacional, aunque no fue el mejor clínicamente. Simulated Annealing quedó muy cercano a FIFO en score balanceado, con mejor comportamiento clínico en varios indicadores pero mayor overhead.

9.2. Ranking balanceado por escenario

Escenario	Rango	Algoritmo	Score balanceado
Normal	1	A*	0.94
Normal	2	FIFO	0.863333
Normal	3	Simulated Annealing	0.853333
Normal	4	CP-SAT	0.78
Normal	5	Greedy	0.756667
Alta demanda	1	A*	0.94
Alta demanda	2	FIFO	0.86
Alta demanda	3	Simulated Annealing	0.853333
Alta demanda	4	CP-SAT	0.79
Alta demanda	5	Greedy	0.763333
Recursos limitados	1	A*	0.94
Recursos limitados	2	Simulated Annealing	0.863333
Recursos limitados	3	FIFO	0.846667
Recursos limitados	4	CP-SAT	0.783333
Recursos limitados	5	Greedy	0.753333

Tabla 4: Ranking balanceado por escenario.

En condiciones normales y de alta demanda, el orden balanceado fue A*, FIFO, Simulated Annealing, CP-SAT y Greedy. En recursos limitados, Simulated Annealing superó a FIFO y quedó segundo, lo que indica que su exploración de alternativas puede ser útil cuando los recursos son más restrictivos.

9.3. Métricas detalladas del escenario normal

Algoritmo	Atendidos	No atendidos	Espera prom.	Espera máx.	Críticos tardíos	Impacto clínico	Overhead planificación
FIFO	12.5	5.5	104.891	238.9	7.6	49972.97	3.05
Greedy	12.4	5.6	108.278	250.5	7.6	50944.335	9.15
A*	13.1	4.9	67.79	193.9	7	48524.125	30.5
CP-SAT	12.7	5.3	103.787	244.2	7.6	49422.9	45.75
Simulated Annealing	13.1	4.9	98.944	245.2	7.5	47809.96	45.75

Tabla 5: Métricas principales del escenario normal.

En el escenario normal, A* redujo la espera promedio de 104.891 minutos en FIFO a 67.790 minutos. Esto representa una reducción aproximada de 35.4%. A* también aumentó pacientes atendidos de 12.5 a 13.1 y redujo pacientes no atendidos de 5.5 a 4.9. La desventaja principal fue el overhead de planificación, que pasó de 3.05 minutos en FIFO a 30.50 minutos en A*.

Simulated Annealing obtuvo el menor impacto clínico total en el escenario normal, con 47,809.960 frente a 49,972.970 de FIFO y 48,524.125 de A*. Sin embargo, su mayor overhead redujo su posición en el ranking balanceado.

9.4. Métricas comparativas por escenario

Escenario	Algoritmo	Atendidos	Espera prom.	Críticos tardíos	Impacto clínico	Overhead
Alta demanda	A*	13.8	116.87	12.6	137874.03	31
Alta demanda	CP-SAT	13.1	153.635	13	140241.84	46.5
Alta demanda	FIFO	13	158.526	13	141994.6	3.1
Alta demanda	Greedy	12.8	161.962	13	143954.23	9.3
Alta demanda	Simulated Annealing	13.6	143.955	13.1	136932.395	46.5
Recursos limitados	A*	13.4	90.116	7	62810.04	30.7
Recursos limitados	CP-SAT	13.2	129.686	7.8	64342.675	46.05
Recursos limitados	FIFO	12.8	129.079	7.8	65377.455	3.07
Recursos limitados	Greedy	12.6	132.611	7.8	66965.86	9.21
Recursos limitados	Simulated Annealing	13.4	120.263	7.6	62168.445	46.05
Normal	A*	13.1	67.79	7	48524.125	30.5
Normal	CP-SAT	12.7	103.787	7.6	49422.9	45.75
Normal	FIFO	12.5	104.891	7.6	49972.97	3.05
Normal	Greedy	12.4	108.278	7.6	50944.335	9.15
Normal	Simulated Annealing	13.1	98.944	7.5	47809.96	45.75

Tabla 6: Resumen comparativo de métricas por escenario y algoritmo.

9.5. Hallazgos contra FIFO

Escenario	Hallazgo
Normal	A* reduced Critical Late Patients by 7.9 % versus FIFO
Normal	Simulated Annealing reduced Total Clinical Impact by 4.3 % versus FIFO
Normal	A* reduced Average Waiting Time by 35.4 % versus FIFO
Alta demanda	A* reduced Critical Late Patients by 3.1 % versus FIFO
Alta demanda	Simulated Annealing reduced Total Clinical Impact by 3.6 % versus FIFO
Alta demanda	A* reduced Average Waiting Time by 26.3 % versus FIFO
Recursos limitados	A* reduced Critical Late Patients by 10.3 % versus FIFO
Recursos limitados	Simulated Annealing reduced Total Clinical Impact by 4.9 % versus FIFO
Recursos limitados	A* reduced Average Waiting Time by 30.2 % versus FIFO

Tabla 7: Hallazgos principales contra FIFO como línea base.

Estos hallazgos muestran que A* fue especialmente fuerte en reducción de espera y pacientes críticos tardíos, mientras que Simulated Annealing destacó en reducción del impacto clínico total.

10. Discusión

Los resultados reflejan un compromiso claro entre calidad clínica, eficiencia operativa y costo computacional.

A* domina el ranking balanceado porque logra fuertes reducciones de espera y buen comportamiento en pacientes críticos. Su principal costo es el overhead de planificación, pero el ranking balanceado le asigna más peso a métricas clínicas y operativas que a métricas puramente computacionales.

FIFO conserva buen desempeño global debido a su simplicidad y bajo overhead. Sin embargo, sus decisiones no incorporan riesgo ni deterioro, lo que limita su utilidad en escenarios donde hay pacientes con diferentes niveles de urgencia.

Greedy no alcanzó los mejores resultados. Aunque incorpora heurísticas clínicas, su visión local puede producir decisiones peores que FIFO en algunas métricas, especialmente cuando las prioridades clínicas y restricciones de recursos interactúan de forma no trivial.

CP-SAT no dominó, a pesar de ser un método de optimización formal. Esto puede explicarse porque el sistema trabaja con ventanas dinámicas de despacho en una simulación de eventos discretos. CP-SAT podría ser más competitivo si se modelara un horizonte temporal más amplio o una agenda global de servicios.

Simulated Annealing fue uno de los algoritmos más interesantes. En recursos limitados alcanzó el segundo lugar balanceado y en varios escenarios redujo el impacto clínico total respecto a FIFO. Esto sugiere que las metaheurísticas pueden ser útiles cuando se necesita explorar alternativas sin formular un modelo exacto completo.

11. Limitaciones y posibles mejoras

11.1. Limitaciones

- La corrida final usa MIMIC-IV-ED Demo, no la versión completa del dataset.
- El enriquecimiento LLM no constituye validación médica real.
- La calidad de las variables generadas por el LLM depende del prompt, del modelo y de la normalización.
- El artefacto final agregado no preserva trazas completas de asignación de recursos por paciente.
- CP-SAT se usa en ventanas locales, no como optimizador global de todo el horizonte.
- No se integró con sistemas hospitalarios reales.
- No se calibraron pesos clínicos con expertos médicos.

11.2. Mejoras futuras

- Guardar trazas completas de pacientes y recursos en el runner final.
- Añadir calibración clínica supervisada por expertos.
- Comparar varios LLMs bajo el mismo protocolo, incluyendo Mistral como proveedor alternativo soportado.
- Incorporar predicción estadística de llegada de pacientes.
- Implementar CP-SAT de horizonte extendido.
- Añadir intervalos de confianza y pruebas estadísticas.
- Integrar dashboards de análisis post-experimento.
- Validar el modelo con escenarios sintéticos extremos diseñados por especialistas.

12. Conclusiones

El proyecto cumple el objetivo de integrar simulación, enriquecimiento clínico mediante LLM y algoritmos de planificación para estudiar la priorización de pacientes bajo recursos limitados.

La corrida final demuestra que A^* fue el algoritmo con mejor desempeño balanceado en los tres escenarios evaluados. FIFO confirmó su valor como baseline computacionalmente barato, pero clínicamente menos expresivo. Simulated Annealing mostró resultados competitivos y podría ser una alternativa útil en escenarios con recursos limitados. CP-SAT ofreció una formulación formal, aunque en la configuración actual no dominó los resultados.

El uso de Ollama local permitió ejecutar una validación final reproducible sin depender de proveedores externos, con cero fallbacks a mock. Mistral permanece como proveedor alternativo soportado por el software, aunque no fue usado en la corrida final reportada.

13. Reproducibilidad

El repositorio contiene:

- código fuente backend: `backend/`;
- código fuente frontend: `frontend/`;
- configuración Docker: `docker-compose.yml`;
- variables de ejemplo: `.env.example`;
- resultados finales: `report/results/final_ollama_mimic_iv_ed/`;
- informe técnico: `report/informe_tecnico.md`.

14. Archivos de entrega

- Código fuente backend: `backend/`
- Código fuente frontend: `frontend/`
- Configuración Docker: `docker-compose.yml`
- Variables de ejemplo: `.env.example`
- Resultados finales completos: `report/results/final_ollama_mimic_iv_ed/`
- Informe final Markdown: `report/informe_final.md`
- Informe final L^AT_EX: `report/informe_final.tex`

Referencias

- [1] Johnson, A. E. W. et al. *MIMIC-IV-ED v2.2*. PhysioNet. Disponible en: <https://physionet.org/content/mimic-iv-ed/>
- [2] Johnson, A. E. W. et al. *MIMIC-IV, a freely accessible electronic health record dataset*. Scientific Data, 2023. Disponible en: <https://www.nature.com/articles/s41597-022-01899-x>
- [3] Goldberger, A. L. et al. *PhysioBank, PhysioToolkit, and PhysioNet*. Circulation, 2000. Disponible en: <https://physionet.org/>